

Bioestadística en tiempo de pandémia

Antonio Falcó

Seminario 1

Introducción

Un caso a estudio: La evolución de la mortalidad en la Comunidad Valenciana durante la pandémia

Objetivo de los seminarios de Bioestadística

Vamos a trabajar para comprender, analizar e intentar predecir los efectos de la pandémia provocada por el COVID-19 en el ámbito de la Comunidad Valenciana.

Evaluación de los seminarios

Cada alumno entregará un cuaderno de campo con las respuestas, notas y conclusiones a las cuestiones propuestas durante cada uno de los seminarios. El cuaderno de campo se entregará de forma individual y se puede descargar un modelo de la página https://github.com/afalco/Seminarios_Bioestadistica. El fichero se llama `cuaderno_de_campo.docx`. Cada alumno re-nombrará el fichero como `Nombre_Apellido1_Apellido2.docx`.

El estudio de una epidemia

Bioestadística en
tiempo de pandémia

Antonio Falcó

Introducción

Un caso a estudio: La
evolución de
mortalidad en la
Comunidad
Valenciana durante la
pandémia

- ▶ La autoridades necesitan conocer la evolución de una epidemia para poder tomar decisiones que salvaguarden la salud de los individuos de una población.
- ▶ ¿que necesitamos observar o medir para comprender y predecir los efectos de la enfermedad sobre los individuos que componen la población?
- ▶ ¿podemos predecir la evolución de una epidemia? o de forma más precisa:
- ▶ ¿podemos construir un modelo predictivo eficaz?
- ▶ ¿qué entendemos por modelo epidemiológico?

Cuestiones científicas

- ▶ ¿Podemos confirmar empíricamente el aumento de la mortalidad en la Comunidad Valenciana debido al efecto del COVID-19?
- ▶ ¿Qué datos nos hacen falta? y ¿dónde los podemos conseguir?
- ▶ ¿Los podemos procesar de manera sencilla?

Las fuentes de datos

Bioestadística en
tiempo de pandémia

Antonio Falcó

Introducción

Un caso a estudio: La
evolución de
mortalidad en la
Comunidad
Valenciana durante la
pandémia

- ▶ <https://data.europa.eu/euodp/es/home>
- ▶ <https://dadesobertes.gva.es/>
- ▶ https://afalco.github.io/DailyReport_COVID.html
- ▶
- ▶ https://momo.isciii.es/public/momo/dashboard/momo_dashboard.html
- ▶ <https://www.ecdc.europa.eu/en/about-us/contact-ecdc>

El formato de los datos

datos.gob.es
reutiliza la información pública

Datos tabulares

CSV

3 Los nombres de las columnas

- No deben repetirse
- Nombres cortos
- Evitar caracteres especiales

4 Estructura vertical

- Siempre que sea posible, el fichero debe actualizarse incorporando nuevas filas y manteniendo fijas las columnas.

5 Valores desconocidos

- A los valores "desconocidos" o "no obtenidos" se les asignarán un código común. Por ejemplo: "NA".
- El código que se utiliza para indicar los valores desconocidos debe especificarse en el diccionario de datos.

Conceptos básicos

- Una sola tabla de datos por archivo.
- La primera fila puede contener exclusivamente el nombre de los campos (cabecera). Es optional.
- Cada observación/registro es una línea.
- Cada variable/campo es una columna.
- Todas las filas deben contener el mismo número de campos.
- Cada campo está separado del siguiente por un carácter singular: ";" ", " | " o "(TAB)". Tener en cuenta el separador decimal para elegir el carácter separador.
- Codificación de caracteres UTF-8.

6 No totales o subtotales

- No deben incluirse columnas o filas que representen agrupamientos de otras.

7 Tipo de datos por columna

- Usar un tipo de datos por columna.
- Las unidades deben describirse en el diccionario de datos.

8 Valores estandarizados

- Usar vocabularios y normas estandarizadas.
- Utilizar la misma codificación y normalización para el mismo tipo de dato publicado en diferentes datasets.

Diccionario de datos

- Cualquier información que no sea dato (esquemas, tablas, columnas, descripciones, comentarios o unidades de medida) debe incluirse en un diccionario de datos.
- Debe expresarse en un formato procesable, por ejemplo, XML o JSON-LD, mediante un vocabulario estandarizado que permita definir cada una de las características de los elementos del archivo de datos. W3C recomienda un vocabulario para la descripción de datos tabulares.
- De las propiedades que existen para describir, tablas, filas, columnas o celdas, es recomendable usar, al menos:

Para las
tablas

Nombre de tabla ["@title"]
Descripción ["@description"]
Ubicación del archivo que se describe ["@url"]

Para las
columnas

Nombre de columna ["name"]
Unidad de medida ["unit"]
Descripción ["@description"]
Tipos de datos ["@datatype"]

9 Campos codificados

- Categorizar los datos para poder extraer patrones o aplicar filtros usando esquemas de conceptos y códigos con valores pre establecidos.

10 Campos de texto

- Valores que incluyen comas o saltos de línea deben ser enteras.
- El contenido entre comillas dentro de un valor debe ir doblemente entrecerrillado.
- Los campos con valores numéricos que incluyen ceros a la izquierda significativos deben ser de tipo texto.

11 Campos numéricos

- No usar separadores de miles.
- El separador decimal depende de la configuración regional (En España usar ".").
- Valores negativos irán precedidos del signo "-". No usar parentesis.
- Es recomendable multiplicar y expresar las unidades de medida o de medida asociadas a valores numéricos.

12 Campos fecha

- Usar el formato ISO 8601: YYYY-MM-DD (fecha abreviada) o YYYY-MM-DDTHH:MM:SS (fecha completa).
- Usar formato 24 horas.
- Para indicar un mes es arconsejable ajustar al último día del mes (2019-09-30).

13 Campos teléfono

- Mantener siempre el mismo formato.
- Se recomienda incluir código de país.

14 Campos dirección postal

- Usar campos separados para codificar los elementos necesarios para localizar una dirección postal: tipo de vía; nombre de la vía; localidad; código postal.

15 Coordenadas geográficas

- Especificar latitud y longitud en columnas separadas y en grados decimales.

1	slug_navea	modelo	año	consumo	emisiones	codice	descripcion	punto_venta	moneda	fecha_venta	proximidad_venta	codigo_venderder	actividad_venderder	latitud	longitud	telefono	correo_electronico	localidad	c_postal	telefono	latitud	longitud
2	000034070236	Chevrolet Chevele Malibu	1970	18	NA	5	M	Manual	23540,23	EUR	18/09/00	2,51	45,11	Venta de automóviles y vehículos de motor ligeros	Calle Avenida, 23, Regio	Alicante	03559	+34-67600000	38,345271	-0,481492		
	000034070243	Buick Skyhawk 320	1970	15	NA	A	Automática	22180,00	EUR	18/09/07	2,69	45,11	Venta de automóviles y vehículos de motor ligeros	Avenida Industria, 33	Oviedo	38201	NA	43,365679	-3,844761			
	000034070256	Plymouth Satellite	1970	18	11	A	Automática	28662,09	USD	18/09/06	3,42	45,19	Venta de otros vehículos de motor ligeros	Calle Carreras, 2, Baja	Madrid	28760	+34-67600003	40,485692	-3,702568			
	000034070258	Amc Rebel st	1970	16	12	M	Manual	29200,00	USD	17/10/01	NA	45,11	Venta de automóviles y vehículos de motor ligeros	Plaza del Vizcón, 23	Huelva	11170	+34-69600008	43,346579	-6,940042			
	000034070621	Ford Torino	1970	17	10,5	M	Manual	31890,10	EUR	18/09/03	2,54	45,19	Venta de otros vehículos de motor ligeros	Plaza Berlina, 1	Lugo	27294	+34-6760123	43,009233	-7,556602			

config: manejador_de_archivos=preferencias_cambios_combustible, desplazamiento_precio, aviso_mensaje_de_error, i18n, promocion, ventanilla_config, ventanilla_descarga, ventanilla_descarga, aviso_mensaje_de_error, punto_venta, telefono, latitud, longitud
000034070236:Chevrolet Chevrolet Malibu:1970,18,NA,M,Manual,23540,23,EUR,18/09/00,2,51,45,11,18/09/07,2,69,45,11,Venta de automóviles y vehículos de motor ligeros,Calle,Avenida,23,Regio,Alicante,03559,+34-67600000,38,345271,0,481492
000034070243:Buick Skyhawk 320:1970,15,NA,A,Automática,22180,00,EUR,18/09/07,2,69,45,11,Venta de automóviles y vehículos de motor ligeros,Avda,Industria,33,Oviedo,38201,NA,43,365679,+3,844761
000034070256:Plymouth Satellite:1970,18,11,A,Automática,28662,09,USD,18/09/06,3,42,45,19,Venta de otros vehículos de motor ligeros,Calle,Carreras,2,Baja,Madrid,28760,+34-67600003,40,485692,-3,702568
000034070258:Amc Rebel st:1970,16,12,M,Manual,29200,00,USD,17/10/01,NA,45,11,Venta de automóviles y vehículos de motor ligeros,Plaza del Vizcón,23,Huelva,11170,+34-69600008,43,346579,-6,940042
000034070621:Ford Torino:1970,17,10,5,M,Manual,31890,10,EUR,18/09/03,2,54,45,19,Venta de otros vehículos de motor,Plaza,Berlina,1,Lugo,27294,+34-6760123,43,009233,-7,556602

Captura de pantalla

Bioestadística en tiempo de pandémia

Antonio Falcó

Introducción

Un caso a estudio: La evolución de mortalidad en la Comunidad Valenciana durante la pandémia

https://datos.gob.es/sites/default/files/doc/file/guia_csv_vf.pdf

Introducción

Un caso a estudio: La evolución de mortalidad en la Comunidad Valenciana durante la pandémia

Los ficheros en formato CSV se pueden abrir y manipular con

- ▶ Excel,
- ▶ LibreOffice,
- ▶ OpenOffice,
- ▶ Editor de texto plano.

en general se emplean para guardar datos que se cargan directamente.

Veamos dos ejemplos

- ▶ Los datos sobre la distribución geográfica en el mundo del COVID-19.
- ▶ Los datos de mortalidad diaria en España.

Para ello emplearemos el programa de estadística R que permite cargar directamente los datos.

```
#these libraries need to be loaded
library(utils)

#read the Dataset sheet into R. The dataset will be called data.
data <- 
read.csv("https://opendata.ecdc.europa.eu/covid19/casedistribution/csv")
na.strings = "", fileEncoding = "UTF-8-BOM")

## Warning in scan(file = file, what = what, sep = sep, quote =
quote, dec = dec, :  entrada inválida encontrada en la conexión
de entrada
'https://opendata.ecdc.europa.eu/covid19/casedistribution/csv'

colnames(data)

## [1] "dateRep"                  "day"
## [3] "month"                    "year"
## [5] "cases"                     "deaths"
## [7] "countriesAndTerritories" "geoId"
## [9] "countryterritoryCode"     "popData2018"
## [11] "continentExp"
```

Introducción

Un caso a estudio: La evolución de mortalidad en la Comunidad Valenciana durante la pandémia

```
library(utils)
library(httr)
#####
#download the dataset from the MOMO website to a local temporary file
GET("https://momo.isciii.es/public/momo/data",
  authenticate(":", ":" , type="ntlm"),
  write_disk(tf <- tempfile(fileext = ".csv")))

## Response [https://momo.isciii.es/public/momo/data]
##   Date: 2020-04-23 18:34
##   Status: 200
##   Content-Type: text/csv; charset=utf-8
##   Size: 17.1 MB
## <ON DISK>  /var/folders/c3/3tnzsl9d65d8djmrzb4m363m0000gt/T//Rtmp5E87AW/file15a

#read the Dataset sheet into R.
#The dataset will be called "data".
data <- read.csv(tf)
#####
```

Introducción

Un caso a estudio: La evolución de mortalidad en la Comunidad Valenciana durante la pandémia

```
colnames(data)
```

```
## [1] "ambito"                      "cod_ambito"  
## [3] "cod_ine_ambito"                "nombre_ambito"  
## [5] "cod_sexo"                     "nombre_sexo"  
## [7] "cod_gedad"                    "nombre_gedad"  
## [9] "fecha_defuncion"              "defunciones_observadas"  
## [11] "defunciones_observadas_lim_inf" "defunciones_observadas_lim_sup"  
## [13] "defunciones Esperadas"        "defunciones Esperadas_q01"  
## [15] "defunciones Esperadas_q99"
```

¿Cómo podemos saber que contiene cada columna? La función `head()`

```
head(data$ambito)
```

```
## [1] nacional nacional nacional nacional nacional nacional  
## Levels: ccaa nacional
```

```
head(data$nombre_ambito)
```

```
## [1] <NA> <NA> <NA> <NA> <NA> <NA>  
## 19 Levels: Andaluc\303\255a Arag\303\263n ... Rioja, La
```

```
head(data$fecha_defuncion)
```

```
## [1] 2018-04-05 2018-04-06 2018-04-07 2018-04-08 2018-04-09 2018-04-10  
## 749 Levels: 2018-04-05 2018-04-06 2018-04-07 2018-04-08 ... 2020-04-22
```

```
head(data$defunciones_observadas)
```

```
## [1] 1193 1163 1154 1068 1098 1155
```

Bioestadística en
tiempo de pandémia
Antonio Falcó

Introducción

Un caso a estudio: La
evolución de
mortalidad en la
Comunidad
Valenciana durante la
pandémia

Fijamos las fechas de defunción en formato de fecha (Año-Mes-Día)

```
data$fecha_defucion <- as.Date(data$fecha_defucion)
```

Creamos una nueva base de datos empleando la función de R `data.frame()` que seguimos llamando `data` y que contiene a las variables `data$nombre_ambito`, `data$nombre_sexo`, `data$nombre_gedad` y las columnas de la 9 a la 15 que contienen todas las variables numéricas: `data[9:15]`

```
data <- data.frame(data$nombre_ambito,
data$nombre_sexo,data$nombre_gedad,data[9:15])
```

Creamos una base de datos solo de la Comunidad Valenciana, para ello consideramos aquellas columnas de `data` cuyo valor para la variable


1. `data$nombre_ambito` = Comunidad Valenciana,
2. `data$nombre_sexo` = todos
3. `data$nombre_gedad` = todos

```
dataCV <- data[data$data.nombre_ambito=="Comunitat Valenciana"
& data$data.nombre_sexo=="todos"
& data$data.nombre_gedad=="todos",]
dataCV <- na.exclude(dataCV) #Excluimos los datos en blanco NA
```

Introducción

Un caso a estudio: La evolución de mortalidad en la Comunidad Valenciana durante la pandémia

Comunidad Valenciana



¿Qué podemos deducir de esta gráfica?

El gráfico anterior se generó con las funciones siguientes:


```
plot(dataCV$defunciones_observadas~as.Date(dataCV$fecha_defuncion, "%y/%m/%d"),
      type='l', ylab="Defunciones Observadas",
      xlab="Date", col="blue", main="Comunidad Valenciana")
lines(dataCV$defunciones Esperadas~as.Date(dataCV$fecha_defuncion, "%y/%m/%d")
      , type='l', col="red", lwd=2)
legend("topleft", legend=c("Reported", "Mean"),
      lty=c(1,1), col=c("blue", "red"))
```

- ▶ Para poder comparar si realmente la pandémia provocada por el COVID-19 ha provocado un aumento de los fallecidos en la Comunidad Valenciana, vamos a comparar los mismos periodos de tiempo en 2019 y 2020

```
fecha_inicio_1 <- as.Date("2020-01-01")
fecha_final_1 <- as.Date("2020-04-21")
fecha_inicio_0 <- as.Date("2019-01-01")
fecha_final_0 <- as.Date("2019-04-22")
# 2019 es año bisiesto y hay 29 de Febrero
```

Introducción

Un caso a estudio: La evolución de mortalidad en la Comunidad Valenciana durante la pandémia



¿Qué podemos deducir de esta gráfica?

Construimos dos series diferentes para cada uno de los dos periodos de tiempo

```
dataCV1 <- dataCV[dataCV$fecha_defuncion >= fecha_inicio_1  
& dataCV$fecha_defuncion <= fecha_final_1,]  
dataCV0 <- dataCV[dataCV$fecha_defuncion >= fecha_inicio_0  
& dataCV$fecha_defuncion <= fecha_final_0,]
```

El gráfico anterior se generó con las funciones siguientes:

```
plot(dataCV1$defunciones_observadas ~ as.Date(dataCV1$fecha_defuncion, "%y/%m/%d")  
, type='b', ylab="Defunciones Observadas",  
xlab="Date", col="blue", lwd=2, ylim=c(100, 220))  
lines(dataCV0$defunciones_observadas ~ as.Date(dataCV1$fecha_defuncion, "%y/%m/%d")  
, type='b', col="red", lwd=2)  
legend("topleft", legend=c("2020", "2019"),  
lty=c(1,1), col=c("blue", "red"))
```


Calculamos la diferencia en los fallecimientos entre los dos periodos de tiempo de interés:

```
diferencias <- (dataCV1$defunciones_observadas - dataCV0$defunciones_observadas)
```

Y construimos la serie temporal constante de la diferencia media y dos series temporales constantes que contienen $\pm 1.5\sigma$:

```
mu <- rep(mean(diferencias), length(diferencias))
two_sigma <- rep(1.5*sd(diferencias), length(diferencias))
```

Diferencias entre fallecidos 2020 – 2019 en la Comunidad Valenciana



¿Qué podemos deducir de esta gráfica?

El gráfico anterior se generó con las funciones siguientes:

```
plot(diferencias~as.Date(dataCV1$fecha_defuncion),type="b",col="blue",  
xlab = "Day",ylab="Defunciones 2020 - Defunciones 2019",  
main="Diferencias entre fallecidos \n 2020 - 2019 en la Comunidad Valenciana",lwd=2)  
lines(mu~as.Date(dataCV1$fecha_defuncion),type='l',col="red",lwd=1)  
lines(mu+two_sigma~as.Date(dataCV1$fecha_defuncion),type='l',col="green",lwd=1)  
lines(mu-two_sigma~as.Date(dataCV1$fecha_defuncion),type='l',col="green",lwd=1)
```